

TP3 - Organização e Recuperação da Informação

Análise de Resultados com e sem Stemming

Matheus Gualter Silva Resende - 12311BSI310

João Guilherme Araújo Viana - 12311BSI238

Consulta 1: "Baby I'm losing control in this cruel summer"

Rank	Documento (Sem Stemming)	Similaridade	Documento (Com Stemming)	Similaridade	Mudança?
1	12 - Cruel Summer	0.3005	01 - Lose Control	0.3664	↑ Subiu
2	01 - Lose Control	0.2448	12 - Cruel Summer	0.3546	↓ Desceu
3	08 - Million Dollar Baby	0.0715	08 - Million Dollar Baby	0.0805	Posição
4	05 - Lovin on Me	0.0701	05 - Lovin on Me	0.0772	Posição
5	13 - Greedy	0.0379	13 - Greedy	0.0416	Posição

Nesta consulta, o stemming provocou uma alteração notável no topo do ranking. A palavra "losing" na consulta foi reduzida ao seu radical "lose". Isso fortaleceu diretamente a correspondência com o documento "01 - Lose Control", que contém o termo "lose" repetidamente em seu refrão. Como resultado, a similaridade deste documento aumentou de 0.2448 para 0.3664, fazendo-o subir para a primeira posição e ultrapassar "12 - Cruel Summer". As demais posições se mantiveram, com um leve aumento geral nos scores de similaridade.

Consulta 2: "Sweet love and beautiful things"

Rank	Documento (Sem Stemming)	Similaridade	Documento (Com Stemming)	Similaridade	Mudança?
1	03 - Beautiful Things	0.3851	03 - Beautiful Things	0.4578	Posição
2	10 - Too Sweet	0.1781	10 - Too Sweet	0.2104	Posição
3	07 - Espresso	0.0773	05 - Lovin on Me	0.1018	↑ Novo
4	15 - Birds of a Feather	0.0346	07 - Espresso	0.0898	↓ Desceu
5	13 - Greedy	0.0264	15 - Birds of a Feather	0.0402	↓ Desceu

O impacto mais claro do stemming nesta consulta foi a entrada do documento "05 - Lovin on Me" para a 3ª posição. A palavra

"Lovin" no título e no refrão da música, que antes era tratada como um termo distinto, foi reduzida ao radical "love" pelo stemmer. Como a consulta continha a palavra "love", a correspondência entre a consulta e este documento foi significativamente fortalecida, aumentando sua similaridade de um valor baixo (não presente no Top 5) para 0.1018, o suficiente para entrar no ranking e deslocar os demais documentos.

Consulta 3: "Million dollar baby, good luck babe"

Rank	Documento (Sem Stemming)	Similaridade	Documento (Com Stemming)	Similaridade	Mudança?
1	18 - Good Luck, Babe!	0.4775	18 - Good Luck, Babe!	0.4801	Sem Mudança
2	08 - Million Dollar Baby	0.1514	08 - Million Dollar Baby	0.1533	Sem Mudança
3	05 - Lovin on Me	0.0634	05 - Lovin on Me	0.0645	Sem Mudança
4	10 - Too Sweet	0.0568	10 - Too Sweet	0.0579	Sem Mudança
5	13 - Greedy	0.0261	13 - Greedy	0.0268	Sem Mudança

Para esta consulta, o stemming teve um impacto praticamente nulo no ranking. Nenhuma posição foi alterada, e os scores de similaridade aumentaram de forma insignificante. A razão para isso é que os termos principais da consulta ("dollar", "baby", "good", "luck", "babe") já se encontram em sua forma raiz ou são nomes próprios que não são alterados pelo Stemmer de Porter. Este é um exemplo excelente de como o stemming pode ser redundante quando os termos já estão em sua forma canônica.

Consulta 4: "Drinking and dancing in a bar song"

Rank	Documento (Sem Stemming)	Similaridade	Documento (Com Stemming)	Similaridade	Mudança?
1	02 - A Bar Song (Topsy)	0.4059	02 - A Bar Song (Topsy)	0.4578	Posição
2	12 - Cruel Summer	0.0801	06 - Not Like Us	0.1245	↑ Novo
3	-	-	12 - Cruel Summer	0.0891	↓ Desceu
4	-	-	05 - Lovin on Me	0.0872	↑ Novo
5	-	-	-	-	-

A aplicação do stemming teve um efeito notável nesta consulta, expandindo os resultados de dois para quatro documentos. O termo "dancing" na consulta foi reduzido para "danc". Isso criou uma nova correspondência com o documento "05 - Lovin on Me", que contém a palavra.

"dance" no final da letra. Além disso, o documento "06 - Not Like Us" entrou no ranking em 2º lugar, o que sugere que a normalização de outros termos na coleção, após o stemming, alterou o cálculo do IDF de forma a aumentar a relevância de outros termos em comum com a consulta.

Consulta 5: "I remember everything about us"

Rank	Documento (Sem Stemming)	Similaridade	Documento (Com Stemming)	Similaridade	Mudança?
1	09 - I Remember Everything	0.2886	09 - I Remember Everything	0.3123	Sem Mudança
2	06 - Not Like Us	0.1040	06 - Not Like Us	0.1115	Sem Mudança
3	17 - Agora Hills	0.0400	17 - Agora Hills	0.0432	Sem Mudança
4	20 - Snooze	0.0197	20 - Snooze	0.0222	Sem Mudança
5	19 - Saturn	0.0142	19 - Saturn	0.0159	Sem Mudança

Similar à consulta 3, esta consulta também não apresentou mudanças no ranking dos documentos. O termo principal, “remember”, já está em sua forma raiz e não é alterado pelo stemmer, como pode ser visto no documento "09 - I Remember Everything". Os outros termos da consulta, como everything e us, ou não são alterados ou são removidos como *stopwords*, fazendo com que a estrutura vetorial dos documentos relevantes permanecesse a mesma em relação à consulta. Isso resultou em um ranking idêntico, apenas com um leve aumento nos scores de similaridade.

Conclusão Geral

A análise dos resultados demonstrou que a aplicação do Stemming de Porter teve um impacto significativo e, em geral, positivo para este experimento. Em 3 das 5 consultas, o stemming provocou mudanças relevantes no ranking, seja alterando a ordem dos documentos mais relevantes ou, mais importante, introduzindo no Top 5 documentos pertinentes que antes eram ignorados.

O benefício foi mais claro em consultas com palavras que possuíam variações morfológicas (ex: “losing”, “dancing”). Por outro lado, em 2 das 5 consultas, o stemming se mostrou redundante, pois os termos-chave já estavam em sua forma raiz. Conclui-se que, para esta coleção e para as consultas elaboradas, o stemming é uma ferramenta valiosa que melhora a revocação (a capacidade de encontrar todos os documentos relevantes) do sistema de recuperação, justificando sua implementação como uma etapa crucial do pré-processamento.